Classificação Automatizada de Doenças em Folhas de Café Robusta em Condições Reais de Cultivo

Etapa 01 — Definição do Problema e Análise Exploratória do Dataset RoCoLe

Natalia Salete Rodrigues
natsalete@ufu.br

Programa de Pós-Graduação em Engenharia Elétrica (PPGEELT)
Universidade Federal de Uberlândia

Docente: Prof^{a}. Dr^{a}. Danielli A. Lima

28 de abril de 2026

Contexto na pós-graduação

Quem sou eu

- Mestranda no PPGEELT/UFU (ingresso 2026)
- Área: *Processamento da Informação*
- Linha: *Metodologias e Técnicas da Computação*

Minha dissertação (24 meses)

- *Deep Learning* para diagnóstico de doenças em folhas de café em condições reais de cultivo
- Foco: arquitetura com módulos de atenção multi-escala adaptados
- Meta: superar 85 % de acurácia em classificação multiclasse no *dataset* RoCoLe

Este TCD

É a **Etapa 2** do meu cronograma de mestrado (Preparação e Análise Exploratória do *Dataset*), antecipada dentro da disciplina.

Duplo ganho

Entrego a Etapa 01 do TCD **e** produzo material reutilizável na minha dissertação.

Motivação

O problema econômico

- Brasil: ∼37 % da produção mundial de café
- Doenças foliares podem comprometer até 30 % da safra se não tratadas a tempo

O problema técnico

- Diagnóstico visual manual é lento, subjetivo e exige especialista
- Modelos atuais de *deep learning* são treinados em imagens de laboratório (fundo uniforme) — não generalizam para o campo

Oportunidade

Dataset RoCoLe traz imagens capturadas **diretamente no campo** — fundo complexo, iluminação variada, oclusões.

Referência a superar

Santos et al. (2023):
Binária: **95,19 %** (ResNet)
Multiclasse: **78,03 %**

Questão de pesquisa

É possível discriminar automaticamente entre folhas saudáveis e folhas afetadas por diferentes patologias foliares (ferrugem em quatro níveis de severidade e ácaro-vermelho) em imagens de café robusta capturadas em condições reais de cultivo, utilizando uma representação tabular compacta de cor, textura e qualidade de imagem, de modo a estabelecer uma ***linha de base classificatória*** *para confronto futuro com deep learning?*

- **Tarefa binária:** saudável vs. doente
- **Tarefa multiclasse:** seis classes (1 saudável + 5 patológicas)

Dataset RoCoLe

Origem: Mendeley Data, DOI 10.17632/c5yvn32dzg.2
Autoria: Parraga-Alava et al. (2019)

Conteúdo

- 1.560 imagens `.jpg`
- 4 formatos de anotação (CSV, JSON, COCO, Pascal VOC) + XLSX de classes
- Capturadas *in situ* em plantações de café robusta

Rotulagem

- **Binária:** *healthy* vs. *unhealthy*
- **Multiclasse:** *healthy*, *rust_level_{1..4}*, *red_spider_mite*

Desafios do *dataset*

- Fundos complexos (solo, galhos, outras folhas)
- Variação de iluminação natural
- Múltiplos dispositivos de captura
- Oclusões parciais

Pipeline de preparação: de imagem a tabela

Por que tabular?

- Escolhi o **KNIME** como ferramenta por reunir, em um só ambiente, tudo que o TCD pede (classificação, avaliação e visualização)
- Quero uma **linha de base** clássica para confrontar depois com o *deep learning* da dissertação

Saída

- `rocole_features.csv`
- 1.560 linhas $\times$ 26 *features* $+$ 2 rótulos

Grupos de *features* extraídas

Grupo	**#**
Estatísticas de cor RGB	6
Estatísticas de cor HSV	6
Proporções cromáticas (saudável, ferrugem, necrose)	3
Textura GLCM (Haralick)	6
Dimensões da imagem	3
Qualidade (brilho, Laplaciano)	2
Total	**26**

Insight 1 — Desbalanceamento multiclasse severo

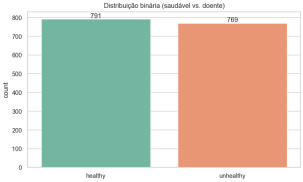

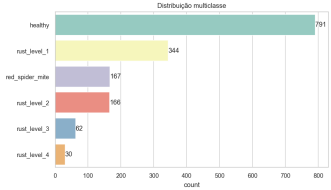

- **Binária:** quase balanceado (791 vs. 769)
- **Multiclasse:** razão 26,4× entre a maior e a menor classe
- Classes de ferrugem com decaimento monotônico: 344, 166, 62, 30

Implicação

Explica a queda de 95 % → 78 % reportada por Santos et al. na transição binária → multiclasse.

Insight 2 — Variabilidade real de aquisição

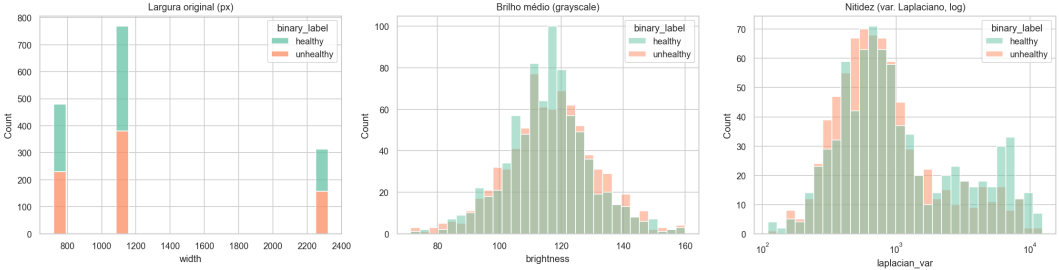

- Resoluções de 720×1280 a 2322×4128 *pixels*
- Brilho médio: $\mu = 116{,}3$, $\sigma = 13{,}9$
- Nitidez (var. do Laplaciano): duas ordens de grandeza (109,8 a 12.363,9)
- **É o que torna o RoCoLe realista** — e difícil de classificar

Insight 3 — Viés sistemático na captura

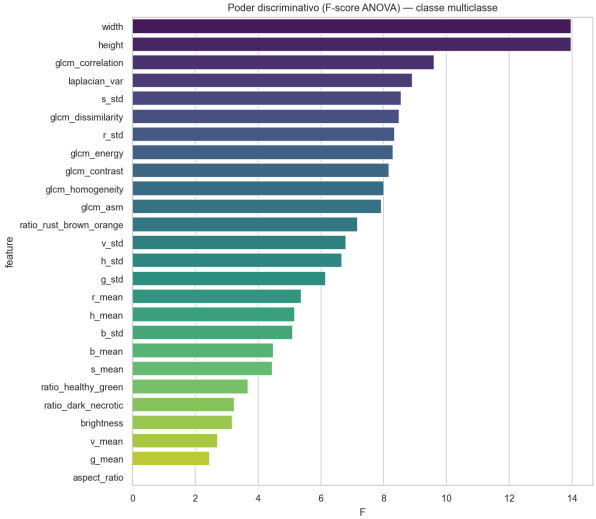

Achado contraintuitivo no F-*score* (ANOVA):

- `width` e `height` aparecem como features mais discriminativas ($F = 13{,}96$, $p < 10^{-12}$)
- `ratio_healthy_green`: **maior** em *rust_level_1* (0,743) do que em *healthy* (0,714)

Interpretação

Diferentes classes foram fotografadas em **sessões distintas** → o modelo pode aprender "atalhos" de aquisição em vez de sintomas reais.

Insight 4 — Redundância entre *features*

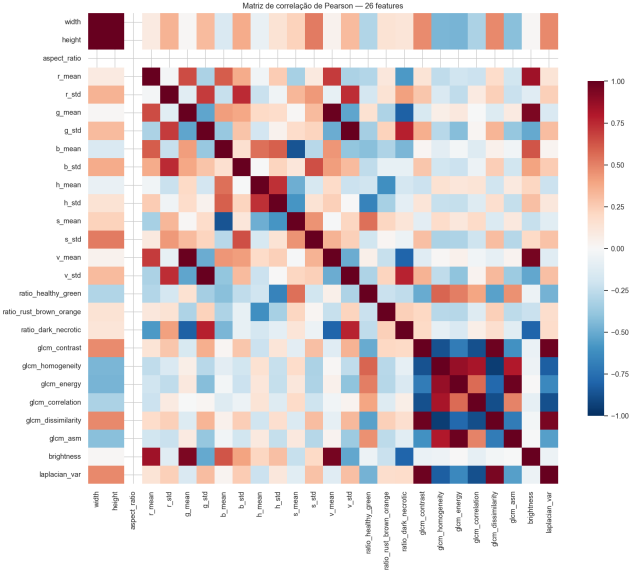

Top-5 pares mais correlacionados ($|r|$):

A	B	$\lvert r \rvert$
`height`	`width`	1,000
`g_std`	`v_std`	0,994
`g_mean`	`v_mean`	0,992
`glcm_contrast`	`laplacian_var`	0,982
`glcm_asm`	`glcm_energy`	0,981

Muitas dessas correlações são matematicamente esperadas (V = máx. de RGB; energia = $\sqrt{\text{ASM}}$).

Insight 5 — Classes não separáveis linearmente

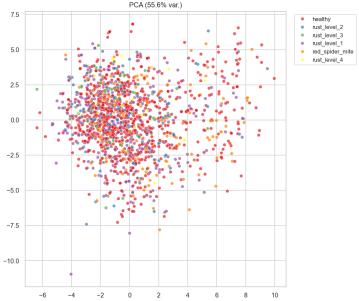

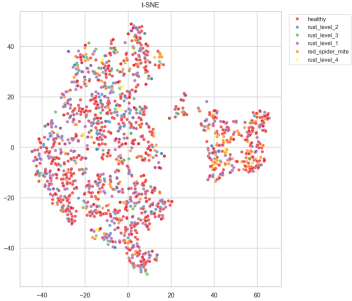

- **PCA:** sobreposição forte — as duas primeiras componentes não separam as classes
- **t-SNE:** pequenos agrupamentos locais, mas sem separação clara global
- Expectativa: classificadores *não lineares* (Random Forest, SVM-RBF) devem superar os lineares

Dificuldades encontradas

- **Anotações em múltiplos formatos**: CSV do Labelbox, JSON, COCO, VOC e XLSX. Escolhi o XLSX de classes por ser o mapeamento mais limpo arquivo→rótulo.
- **Heterogeneidade de resolução**: imagens com até 8 MP exigiram redimensionamento antes do GLCM para manter o custo computacional tratável.
- **Decisão de representação**: converter imagens em *features* tabulares foi uma escolha metodológica não trivial — precisei desenhar *features* que capturassem aspectos visualmente discriminativos (proporções cromáticas por HSV) e justificá-las.
- **Viés de aquisição não previsto**: o achado de que `width/height` são fortemente discriminativos foi inesperado e exige cuidado metodológico nas etapas subsequentes.

Próximos passos — Etapa 02

1. Importar `rocole_features.csv` no **KNIME**
2. **Remover *features* de dimensão** (`width`, `height`, `aspect_ratio`) para mitigar o viés de aquisição identificado
3. Particionamento estratificado 70 % / 15 % / 15 %
4. Treinar e comparar classificadores clássicos: *Decision Tree*, *Random Forest*, *Naïve Bayes*, SVM
5. Avaliação com métricas sensíveis ao desbalanceamento: F1-*macro*, *balanced accuracy*, matriz de confusão
6. Estabelecer **linha de base** quantitativa para posterior confronto com *deep learning* na dissertação

Referências I

1. PARRAGA-ALAVA, J.; CUSME, K.; LOOR, A.; SANTANDER, E. *RoCoLe: A robusta coffee leaf images dataset*. Mendeley Data, v.2, 2019. DOI: 10.17632/c5yvn32dzg.2.
2. SANTOS, L. F. C.; OLIVEIRA, G. M. B.; SILVA, R. R. V. Classificação de doenças em folhas de café robusta utilizando redes neurais convolucionais. In: SBC, *Anais do Workshop de Computação Aplicada à Gestão do Meio Ambiente e Recursos Naturais*. Porto Alegre, 2023. p. 61–70.
3. ESGARIO, J. G. M.; KROHLING, R. A.; VENTURA, J. A. Deep learning for classification and severity estimation of coffee leaf biotic stress. *Computers and Electronics in Agriculture*, v. 169, p. 105162, 2020.
4. MOHANTY, S. P.; HUGHES, D. P.; SALATHÉ, M. Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, v. 7, p. 1419, 2016.
5. BARBEDO, J. G. A. Factors influencing the use of deep learning for plant disease recognition. *Biosystems Engineering*, v. 172, p. 84–91, 2018.
6. BARBEDO, J. G. A. Plant disease identification from individual lesions and spots using deep learning. *Biosystems Engineering*, v. 180, p. 96–107, 2019.
7. HARALICK, R. M.; SHANMUGAM, K.; DINSTEIN, I. Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, v. SMC-3, n. 6, p. 610–621, 1973.
8. MATIELLO, J. B. et al. *Cultura de café no Brasil: manual de recomendações*. 2. ed. Rio de Janeiro: MAPA/PROCAFÉ, 2016.

Referências II

9. Companhia Nacional de Abastecimento. *Acompanhamento da safra brasileira de café*. 2024. Disponível em: `https://www.conab.gov.br`. Acesso em: jan. 2026.

Obrigada!

Dúvidas, sugestões e críticas são muito bem-vindas.

Natalia Salete Rodrigues natsalete@ufu.br
PPGEELT / UFU Mestrado em Engenharia Elétrica